

# 항공사진을 이용한 딥러닝 기반 건물객체의 자동추출 실증연구

## An empirical study on automatic building extraction from aerial images using a deep learning algorithm

서기환\*, 오창화, David Kim, 이민영, 양운정

국토연구원 책임연구원 (khseo@krihs.re.kr)

국토연구원 연구원 (cwoh15th@krihs.re.kr)

국토연구원 연구원 (davidkim@krihs.re.kr)

국토연구원 연구원 (mylee4732@krihs.re.kr)

(주)인스페이스 주임 (yjyang@inspace.re.kr)

### 요 약

본 연구는 대전지역의 항공사진과 딥러닝 기법을 활용해 주거용 건물(단독주택 및 그 외 건물)의 자동추출 가능성을 확인하고자 하였다. 먼저, 영상 객체추출에서 성능이 검증된 Deep U-net과 DeepLab V3+ 기법을 후보로 선정해 훈련셋으로 학습시키고 모델별 학습 소요시간을 평가하였다. 다음은 검증셋에 의한 정확도 결과와 학습 소요시간을 고려해 더 우수한 성능을 나타낸 Deep U-net을 시험셋을 위한 평가 모델로 최종 선정하였다. Deep U-net 모델에 시험셋을 적용한 결과 단독주택과 그 외 건물의 추출결과가 각각 76.1%와 89.1%의 정확도로 도출되었다. 본 연구의 결과는 국토에 대한 상시 모니터링이 국토전역에 대한 동일시점의 시계열 데이터의 지속적 축적에서부터 시작한다고 볼 때 비용 효과적이고 효율적인 모니터링에 기초가 될 것으로 기대된다. 특히, 환경부가 스크린 디지털라이징을 통한 세분류 토지피복도 제작에서 단독주거시설의 분류정확도(76.9%)와 유사한 결과를 나타내 향후 추가적인 연구를 통해 딥러닝 기법을 활용한 토지피복분류 자동화를 위한 기초연구가 될 것으로 기대된다.

### 1. 서론

지속가능한 국토관리는 토지의 계획적 관리와 활용에서 시작된다. 이를 위한 기초자료로서 정부는 토지피복 현황을 정기적(매년)이고 지속적으로 모니터링 할 필요가 있다. 광역적인 토지이용변화 모니터링이나 특정지역의 성장관리를 목적으로 미래 토지이용변화를 시뮬레이션하기 위해서는 전 국토에 대한 토지이용현황 자료가 일정 주기의 시계열자료로 구축되어야 한다. 이와 관련한 기초연구로 고해상도 위성영상 및 기상관측영상, 시계열 영

상 등을 활용한 토지이용현황 및 변화탐지에 관한 연구가 다수 수행되었다. KOMPSAT-2(아리랑 2호 등)고해상도 위성영상을 활용한 토지피복도 자동추출 연구[1], 고해상도 위성영상을 활용한 버재배지 파악 연구[2], 주거지역과 녹지면적의 변화 탐지 연구[3] 등이 수행되어 왔다. 또한 NASA가 운용하는 기상관측용 위성인 Terra의 모디스(MODIS : Moderate Resolution Imaging Spectroradiometer)를 활용하여 북한지역의 토지피복과 식생변화에 관한 연구[4], 시계열 landsat 영상 자료를 감독분류하여 토지피복도의 변화

와 예측을 수행한 연구[5], 아리랑 2호 영상을 활용하여, 갯벌지역의 토지피복 및 이용변화를 탐지한 연구[6]가 있다.

우리정부(국토부·환경부)는 지금까지 전통적인 방식으로 토지이용 또는 토지피복 현황 자료의 구축에 많은 시간과 예산(1998년부터 토지피복도 제작에만 150억 원 이상)을 투입 하였다. 정부의 이러한 투자에도 불구하고 국토지리정보원의 토지이용현황도나 환경부 토지피복도는 자료의 현재성과 정확성, 시계열자료의 부재로 인해 활용성이 낮게 평가되고 있다[7].

한편, 영상처리 및 분류 자동화를 통해 기존의 방법론이 갖고 있는 분류정확도, 시간 및 비용 등의 한계를 극복하고자 하는 시도들이 다양하게 진행되고 있다. Inglada *et al.*[8]은 자가 학습 분류(automated supervised classification)기법을 통해 토지피복분류 제작의 자동화를 시도하는 연구를 수행하였고, 미국의 체사피크 환경관리단(Chesapeake Conservancy)과 미시건 주 오클랜드지역도 딥러닝(U-net) 알고리즘을 활용하여 토지피복도 제작에 활용하였다. Qin, *et al.*[9]은 스위스 취리히 지역의 항공사진과 인공지능 알고리즘을 접목해 건축물의 변화탐지를 수행하였다. MIT의 컴퓨터 공학 및 AI연구팀은 항공사진과 머신러닝을 활용해 정밀 도로지도를 만드는 로드트레이서를 개발하였다. 원석환[10]은 북한지역의 Landsat 영상을 머신러닝 기법을 이용해 학습시키고, 토지이용변화를 시뮬레이션 하였으며, 송아람 등[11]은 항공초분광센서 영상에 CNN 알고리즘을 적용해 토지피복 분류를 시도하였다. 위성영상과 머신러닝(Random Forest)을 이용해 재해에 따른 건물파괴 등 재해지역 탐지[12]에 관한 연구도 수행되었고, RapidEye 영상에 머신러닝 및 딥러닝 기법을 적용하여 벼 재매 면적지를 분류하는 연구[13] 등 다양한 연구가 수행된 바 있다.

본 연구는 이러한 최근의 연구 트렌드를 고려하고, 기존의 토지이용 및 토지피복현황 모니터링이 안고 있는 문제를 완화하고자 항공사진에 딥러닝 기법을 적용

하여 상대적으로 적은 비용으로 매년 토지피복자료의 제작 또는 갱신이 가능한 방법론 개발을 위한 기초연구를 수행하고자 한다.

## 2. 연구방법

### 2.1 연구 대상지

본 연구는 대전광역시를 연구 대상지역으로 선정하였다. 대전광역시의 주택 수는 그림 1과 같이 지난 10여년(2005~2015) 동안 464,500호에서 595,200호로 지속적인 증가 추세를 보이고 있다. 아울러 행정구역별로 원도심·신시가지·도시형 생활주택 등 다양한 유형의 건물이 있어 주거용 건물 객체의 추출을 위한 대상지역으로 적합한 것으로 판단하였다.




그림 1 대전광역시 주택 수 추이('05~'15), [14]

### 2.2 연구수행 방법

본 연구는 딥러닝 이용해 건물 객체를 학습하고 객체추출의 자동화 가능성을 알아보고자 하는 연구이다. 본 연구에 적합한 모델의 선정을 위해 사전적으로 선행 연구들을 검토하고, 영상분류에 활용되고 있는 딥러닝 기법들에 대해 살펴보았다. 동시에 대상지역인 대전광역시의 주택현황에 대해 항공사진을 통해 데이터 셋을 구축하여 연구목적과 구축된 데이터의 특성에 적합한 딥러닝 기법을 탐색하고자 하였다.

#### 2.2.1 적용 알고리즘 후보 선정

딥러닝에는 다양한 기법이 있다. 본 연

구에서는 딥러닝의 문제해결 방식인 분류(Classification), 탐지(Detection), 의미론적 분할(Semantic Segmentation) 가운데 픽셀단위로 대상을 분리하고, 내용 및 위치정보를 파악에 적합한 의미론적 분할 방식의 모델들로 후보군을 좁혔다.

딥러닝 과정에서는 컴퓨터가 스스로 대상의 특징을 학습(비지도학습)하고 분류하는데, 대표적인 알고리즘에는 CNN(Convolutional Neural Network), DBN(Deep Belief Networks), SAE(Stacked Auto-Encoder) 등이 있다. 본 연구는 항공사진을 활용하므로, 영상자료의 특징을 추출하고 분류하는데 보편적으로 활용되는 컨볼루션 신경망(CNN) 알고리즘을 활용하였다. 특히, U-net, Deep U-net, DeepLab, PSPNET, ENet 등 CNN을 기반으로 성능의 향상(데이터 처리속도 및 메모리 사용량)을 위해 고안된 알고리즘 가운데, 본 연구의 분석에 적합하다고 판단되는 후보 알고리즘 두 가지를 선정 한 후, 실제 데이터를 사용해 검증과정을 거쳐 최종 분석모델을 선정 하였다. 후보 알고리즘의 선정은 각 알고리즘의 특징과 선행연구 사례들을 검토하여 선정하였다[15][16].

먼저 의미론적 분할(Semantic Segmentation)에서 자주 활용되는 U-net을 개선하여 작은 객체의 탐지에 적합한 성능을 나타내는 Deep U-net 알고리즘을 첫 번째 후보 알고리즘으로 선택하였다. U-net은 의료영상 분류를 목적으로 고안된 알고리즘으로 접합(Concatenation) 연결방식을 사용하여 CNN에서 발생할 수 있는 공간적 정보 손실을 줄여 영상의 분류정확도를 높인 방식이다. 이를 개선한 방식인 Deep U-net은 항공사진 분류에서 높은 성능을 가지는 것으로 확인되는데, 영상 분류 시 네트워크의 반복으로 발생하는 영상의 손실을 줄이기 위해 다운(Down) 샘플링 과정에서 이전 레이어의 특징을 처리중인 레이어와 결합하는 방식(Plus Layer)으로 영상손실을 줄여 알고리즘의 정확도를 개선한 방식이다. Li의 연구[16]에서는 항공사진과 Deep U-Net을 이용해 분류 정확도를 높인 사례가 있다.




그림 2 Deep U-Net의 상세구조

두 번째는 DeepLab V3+를 후보 알고리즘으로 선정하였다. DeepLab은 기존 CNN 연산의 파라미터 수와 연산량을 감소시키는 알고리즘으로, 전체적인 수행 속도와 사용 메모리의 양을 감소시킨 알고리즘이다. 즉, 일정 간격(rate)마다 연산을 수행하는 방법인 atrous convolution을 활용하는 DCNN(Deep Convolutional Neural Network)와 Fully-Connected CRF(Conditional Random Field)를 통해 기존 인접 픽셀을 대상으로 컨볼루션을 수행하는 경우에 비해 시간과 메모리 사용량을 감소시키면서도 같은 해상도를 가지는 장점이 있다. 또한 DeepLab V3+는 경지 및 산림 등을 분류하는데 적합한 모델로 알려져 있다.

DeepLab은 분석성과 특징적인 면을 고려하여 버전 1에서부터 현재 3+ 버전까지 개발되었다. 버전 3은 ResNet을 사용하여 훈련 중 산출되는 산출물(Output)을 학습에 활용하지 않고, 입력값(Input)과 산출물 차이의 값을 학습에 반영하는데, 이를 통해 딥러닝 모델의 단계가 반복될 때 결과가 더 나빠지는 문제를 해결하고자 하였다. V3+는 V3의 ResNet 대신 Xception(Inception with separable convolution)을 사용하여 파라미터의 수와 연산량을 감소시키는 동시에 기존 Convolution과 유사한 성능을 나타내기 위해 개발되었다.




그림 3 DeepLab 알고리즘

두 모델의 특징을 살펴보면, Deep U-net의 경우 연결된 두 Convolution 레이어를 통해 특징을 추출하는 과정에서 손실을 줄이기 위해 Plus layer를 활용하고 있다. 또한, DeepLab V3+의 경우 Depthwise Separable Convolution에 Atrous convolution을 결합하는 과정을 통해 파라미터 수와 연산량을 줄이며 효율성 개선을 고려하였다.

## 2.3 분석 데이터

### 2.3.1 분석대상 영상 및 참조자료 선정

토지피복분류 방법 및 정확도의 결정은 연구에서 사용된 영상의 종류(위성, 항공사진), 공간해상도와 분광해상도, 촬영면적 등 여러 요소에 따라 결정이 되는데, 본 연구에서는 공간해상도 25Cm급 항공사진을 활용하였다. 고해상도 항공사진은 구체적이고 세분화된 객체분류가 가능하다는 측면과, 국토지리정보원에서 남한 전역에 대한 영상을 매년 2개 권역별로 구축하고 있어, 향후 지속적인 토지이용변화 모니터링이 가능하다는 측면을 고려한 선택이다.

본 연구는 대전지역 항공사진에서 단독주택과 단독주택 외 건물 객체로 구분하였다. 영상데이터의 확인을 위한 참조자료로는 벡터기반 GIS자료인 대전광역시의 GIS건물통합정보와 도로명주소기본도를 비교·검토해 적합한 자료를 사용하였다. 각 GIS벡터자료와 항공영상을 대조하여 건물 객체수, 형상정확도 및 항공사진 촬영 기준시점(2016) 등을 고려하여 GIS건물통합정보의 벡터자료를 데이터 셋 구축을 위한 참조자료로 선정하였다.




그림 4 GIS건물통합정보와 영상자료 중첩 이미지(대전광역시)

### 2.3.2 관심객체 설정

영상 객체 분류를 위해서는 관심객체의 정의가 필요한데, 본 연구는 주거용 건물 가운데 ‘단독주택’을 대상으로 선정하였다. 이는 상대적으로 객체수가 많지만 다양하고 복잡한 형태를 가지고 있어 객체 추출 및 분류 자동화를 검증하기에 적합한 대상으로 판단되었기 때문이다. 단독주택을 기준으로 객체가 건물인지 아닌지, 건물일 경우에는 객체가 단독주택인지에 여부에 따라 ‘0’(건물이 아닌 모든 기타 사물), ‘1’(단독주택), ‘2’(그 외 건물) 3가지 코드로 구분하였다.

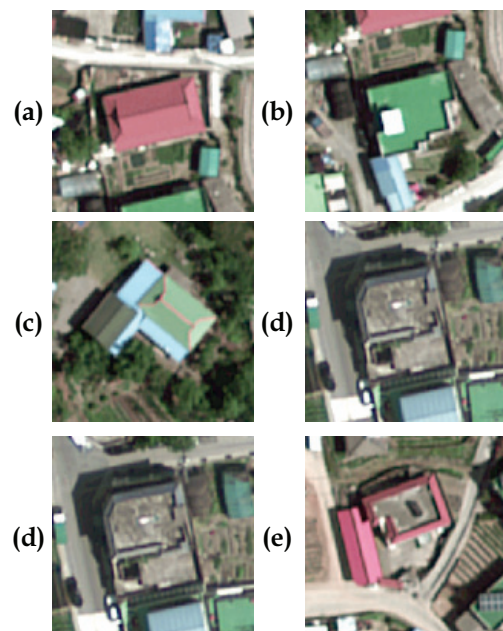


그림 5 단독주택의 다양한 이미지



영상자료로 확인 가능한 단독주택의 유형은 그림 5와 같이 크게 6가지로 분류할 수 있다. 삼각형 모양의 지붕에 색깔이 있는 건물(a), 옥상 방수페인트로 인해 초록색을 띠는 건물(b), 지붕이 있는 옥탑방이 설치된 건물(c), 시멘트 옥상으로 도로나 나대지와 유사한 색상을 보이는 건물(d), 외곽에만 지붕이 있는 건물(e), 옥상에 태양광판을 설치한 건물(f)로 설명할 수 있다.

영상자료 육안판독 시 건물의 측면이 촬영된 경우, 건물이 나무에 가려진 경우, 건물의 일부가 그림자에 가려진 경우 등 제약사항이 존재하였다. 이 경우 최대한 분류 오류를 줄일 수 있는 방향으로 기준을 설정하여 건물을 구획하였다.

### 2.3.3 데이터 라벨링

수집된 대상지역의 영상자료와 벡터자료를 중첩한 후, 건물의 경계와 일치하지 않는 부분을 수정하는 ‘벡터라이징(Vectorizing)’과정을 수행하였다. 이 과정이 완료되면 객체 유형에 따라 코드(0,1,2)를 부여(라벨링)하고, 이미지 형태로 변환하였다.

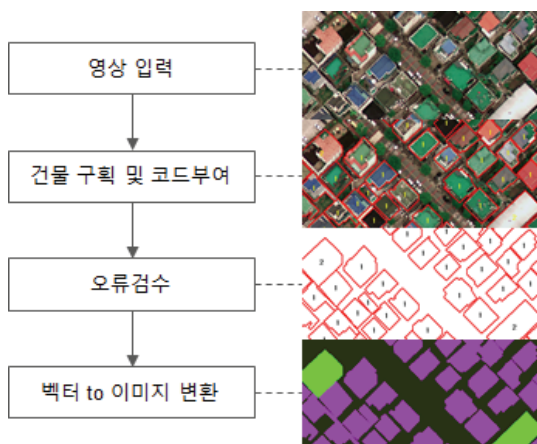


그림 6 데이터 라벨링 과정

영상자료 및 라벨링된 이미지 자료는 64×64m(256×256pixel)단위로 절취하고, 이 두 세트의 자료를 그림 7과 같이 데이터 1set로 설정하였다.

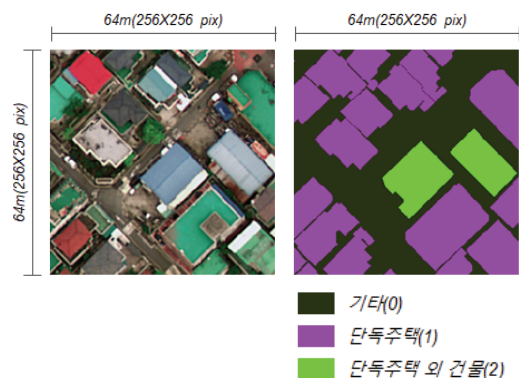


그림 7 데이터 1set (좌:이미지, 우:라벨)

### 2.3.4 데이터 셋의 구축 및 학습

영상 분류 모델을 학습하고, 검증, 시험하기 위해서는 훈련셋·검증셋·시험셋이 필요하다. 검증셋은 일종의 목표치로 본 연구의 분류 정확도를 판단하는데 활용된다. 목표치 도달여부에 따라 훈련셋의 설계와 데이터셋의 양을 변경할 수 있으며, 이렇게 훈련된 모델을 훈련에 사용되지 않는 실제 데이터에 적용하는 과정이 시험셋에 대한 모델의 적용이다. 항공사진과 참조자료인 GIS건물통합정보를 중첩하여 건물의 외곽형상을 정의하는 방식으로 데이터셋을 구축하였는데, 영상과 벡터자료의 불일치가 발생하는 등 경우에 따라 참조자료 대신 새로운 외곽선을 구축하여 활용하기도 하였다. 이러한 과정을 통해 64m×64m의 이미지와 라벨 데이터로 구성된 데이터셋을 정의하였다.

표 1 데이터셋 구성

항목	값
데이터셋 수	30,100set
데이터셋 크기	64m×64m
클래스 수	3(기타, 단독주택, 기타 건물)

일반적으로 데이터셋의 구성 비율은 주로 훈련셋, 검증셋, 시험셋을 7:2:1로 구성하고 있으나, 본 연구의 시간과 비용측면을 고려하여 훈련셋의 비중을 높임으로써 최대한 성능을 높일 수 있도록 훈련셋, 검증셋, 시험셋의 비율을 각각, 93.8%, 5%, 1.2%로 설정하였다.

표 2 데이터셋 구성비율

데이터셋	개수	비율
시험셋(test set)	374set	1.2%
검증셋(validation set)	1,505set	5.0%
훈련셋(training set)	28,221set	93.8%
합계(total)	30,100set	100.0%

모델의 학습을 위하여 딥러닝 분야에 가장 활발하게 사용되는 라이브러리(Library) 중 하나인 구글의 텐서플로우(Tensorflow)와 케라스(Keras)를 활용하였으며, 언어는 Python 3.6을 통해 구현하였다. 먼저 앞서 후보로 선정한 두 알고리즘 각각의 학습시간을 측정하고, 선행연구를 참조해 하이퍼파라미터 설정은 수동 탐색(manual search)방법을 활용하였다. 하이퍼파라미터의 설정 결과는 표 4와 같다.

표 3 모델별 학습 소요 시간

평균소요시간	Deep U-net	DeepLab V3+
1 Epoch	180초	1900초
150 Epoch	약 8시간	약 80시간

표 4 하이퍼파라미터 튜닝 결과

항목	값
배치사이즈(Batch Size)	11
학습정도(EPOCH)	10000
관성(Momentum)	0.9
학습속도(Learning rate)	0.1

### 3. 분석결과

#### 3.1. 객체추출 결과

Deep U-net과 DeepLab V3+에 대한 검증셋 평가결과를 토대로 최종적으로 시험셋에 사용할 모델을 선정하였다. 그림 8은 위에서부터 각각 원본 이미지, Ground truth 이미지, Deep U-net 모델의 검증셋 결과, DeepLab V3+의 검증셋 결과를 나타낸다. 그림 9는 송전탑, 태양광 에너지판, 교량 등 특정 개체에 대한 비교 결과이다.

결과 영상을 육안으로 볼 때, Deep U-net에서는 교량이나 도로 같은 객체에 대해 적절히 분류하였으나, DeepLab V3+는

건물로 오분류하였다. 이러한 오류는 데이터셋을 추가하여 학습하는 등의 방법으로 분류결과를 개선할 수 있다.




그림 8 검증셋 모델 적용결과

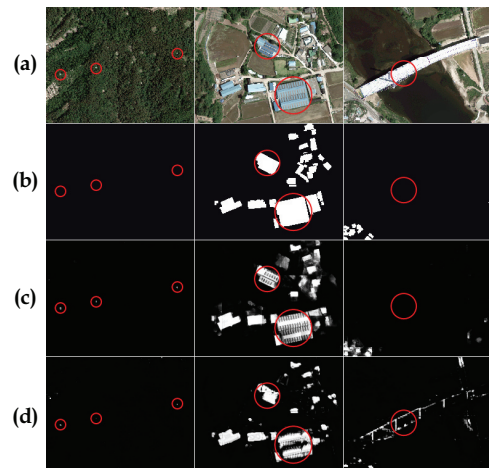


그림 9 검증셋 모델 적용결과 비교

각 모델의 정확도(Accuracy)를 객관적으로 산출하기 위하여 객체 분류 모형의 성능을 측정할 때 사용하는 혼동행렬을 활용하였다[17].

표 5 혼동행렬

구분		알고리즘 수행 결과	
		Positive	Negative
Ground truth	Positive	TP (True Positive)	FP (False Positive)
	Negative	FN (False Negative)	TN (True Negative)

표 5의 True Positive는 Ground truth가 positive(분류하고자 하는 객체, 여기서는 건물)이며, 분류결과가 Ground truth와 일치하는 픽셀을 의미한다. False Positive는 건물에 대한 분류결과가 Ground truth와 다른 것을 의미한다. False Negative는 건물이 아닌 객체에 대한 분류결과가 Ground truth와 다른 것을 의미한다. True Negative는 건물이 아닌 객체에 대한 분류결과가 Ground truth와 일치하는 것을 의미한다.

이에 따라 각 모델의 정인식률(Precision), 성공률(Recall), 정확도(Accuracy)를 산출하였다. 정인식률은 분류하고자 하는 객체의 분류결과 중 제대로 분류한 데이터의 비율을 의미하며, 다음 식을 통해 산출된다.

$$Precision = \frac{TP}{TP+FP}$$

성공률은 전체 데이터 중 모형에 의해 성공적으로 인식된 데이터의 비율을 의미하며, 다음 식을 통해 산출된다.

$$Recall = \frac{TP}{TP+FN}$$

정확도는 전체 데이터의 분류가 성공적으로 이루어진 비율을 의미하며, 다음 식을 통해 산출된다.

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$$

평가결과는 표 6과 같다. 정인식율에서 Deep U-net이 77.2%, DeepLab V3+가 33.9%로 Deep U-net이 더 우수하게 나타났으며, 정확도 역시 Deep U-net이 98.0%, DeepLab V3+가 96.5%로 나타나 Deep U-net이 종합적으로 더 우수한 것

으로 나타났다. 이에 따라 Deep U-net 모델을 최종 시험셋에 적용하여, 객체추출을 수행하였다.

표 6 검증셋 평가결과

구분	Deep U-net	DeepLab V3+
Precision	0.7716643546783453 (77.2%)	0.3387522054509024 (33.9%)
Recall	0.7795049368695686 (78.0%)	0.7690718877226989 (76.9%)
Accuracy	0.9796496825400101 (98.0%)	0.9652348394176762 (96.5%)

이때, 결과 값을 Ground truth와 비교하였을 때 형태가 흐트래지는 경우가 생길 수 있으므로, 분류 이후 Otsu threshold<sup>†</sup>를 사용하여 결과 영상을 이진화하였다. Deep U-net 모형을 시험셋에 이진분류(건물/건물아님)로 적용한 결과는 그림 10과 같다.

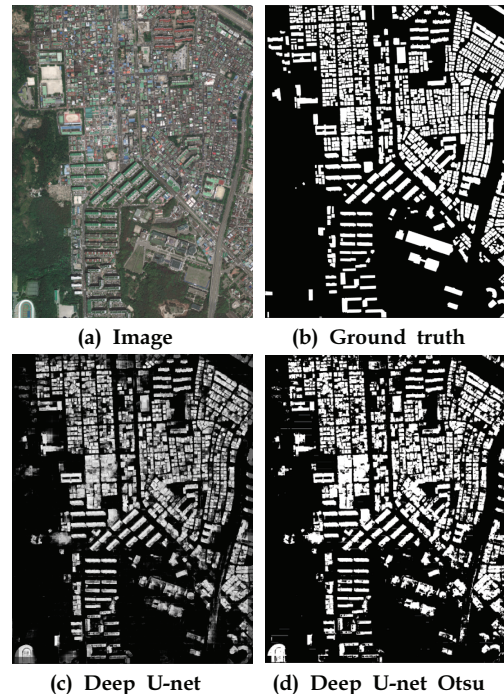


그림 10 이진분류 시험셋 모델 적용결과

그림 11은 시험셋 적용 결과 중 원형경기장, 특이한 옥상 형태, 경지 정리된 밭, 골프연습장 등 다양하게 오분류된 경우를

<sup>†</sup> 클래스를 분류할 때 두 클래스 각각 내의 내적분산(intra-class variance)을 최소화, 또는 두 클래스 사이의 상호분산(inter-class variance)을 최대화하는 특정 임계값을 찾는 이진화 기법임



보여준다. 이러한 객체에 대해서는 추가적으로 데이터셋을 학습시킨다면 개선된 분류결과가 나올 것으로 예상된다.





그림 11 이진분류 시험셋 모델 적용결과 비교

표 7은 이진분류 시험셋에 대한 평가결과이다. Deep U-net 모형은 88.3%의 정확도를 보였으며, 건물의 자동분류가 일정부분 가능함을 확인할 수 있었다.

표 7 이진분류 시험셋 평가결과


구분	Deep U-net
Threshold	95
Precision	0.7771879352162672 (77.7%)
Recall	0.8110369133741421 (81.1%)
Accuracy	0.8827552611125264 (88.3%)

이후 같은 모형과 영상에 대하여 ‘단독주택’, ‘단독주택 이외 건물’, ‘기타’의 세 가지 class로 분류하는 작업을 수행하였다. 이진분류와 마찬가지로, ‘단독주택’과 ‘단독주택 이외 건물’ 두 클래스에 대해 Otsu threshold를 적용하였으며, 그 결과는 그림 12, 13과 같다.



(a) Image


(b) Ground truth



(c) Deep U-net


(d) 이진영상 생성 결과

그림 12 3class 시험셋 모델 적용결과 - 단독주택 결과



(a) Image

(b) Ground truth



(c) Deep U-net

(d) 이진영상 생성 결과

그림 13 3class 시험셋 모델 적용결과 - 단독주택 이외 건물 결과

결과에서 볼 때, Deep U-net은 건물과



건물이 아닌 객체는 자동으로 추출할 수 있음을 확인하였으나, 단독주택과 단독주택 이외 건물의 분류는 잘 이루어지지 않은 것으로 나타났다.

단독주택, 단독주택 외 건물 및 기타지역 등 3 class에 대한 분류 평가 결과는 표 8과 같다. 정확도 평가에서는 단독주택(76.1%)과 단독주택 이외 건물(89.1%)이 비교적 높게 나타났다. 정확도만 고려할 경우 환경부의 세분류 토지피복분류의 단독주거시설에 대한 분류정확도(76.9%)와 유사한 결과를 나타낸다. 그러나, 정인식률과 성공률에서 보면 모두 30% 보다 낮게 나타나 분류가 제대로 이루어졌다고 보기 어렵다. 이는 항공사진의 분광정보만으로 건물의 용도를 구분하는데 한계가 있음을 나타낸다. 즉, 항공사진만으로 단독주택과 단독주택이 아닌 건물을 구분하기는 어려워 보인다. 단독주택과 타 용도의 건물을 구분하는 특성 중 건물의 높이에 대한 정보를 추가적으로 학습시킨다면, 두 종류의 건물에 대한 분류 정확도 향상을 기대할 수 있을 것이다. 따라서 데이터셋을 구축할 때 DEM이 아니라 건물, 수목 등의 높이를 포함하는 수치표면모델(DSM; Digital surface model)을 학습시키는 것을 고려한다면 분류 정확도 향상에 기여할 수 있을 것으로 판단된다.

표 8 3 class 시험셋 평가결과

구분	단독주택(1)	단독주택 외 건물(2)
Precision	0.1809443117674356 (18.1%)	0.030654418338681957 (3.1%)
Recall	0.26896163030063414 (26.9%)	0.13277688780105468 (13.3%)
Accuracy	0.7609552208352204 (76.1%)	0.891373086090825 (89.1%)

#### 4. 요약 및 결론

본 연구는 지속가능한 국토 관리의 출발점인 국토현황에 대한 비용효과적이고 효율적인 모니터링 방안을 모색하기 위한 기초연구로서 항공사진과 딥러닝 기법을

이용해 객체의 자동추출 가능성을 실증하고자 하였다.

세분류 수준의 토지피복도 제작을 고려해 지상 객체 중에서도 작고, 다양한 패턴을 가진 건물(단독주택과 단독주택 외 건물)을 추출 대상으로 하고, 건물이 많고 다양한 대전지역을 대상지역으로 선택하여 연구를 수행하였다.

딥러닝 방법으로는 Deep U-net과 DeepLab V3+에 데이터셋을 훈련시켜 성능이 우수한 Deep U-net을 최종 객체추출에 활용하였으며, 검증셋, 시험셋의 결과 건물과 건물이 아닌 객체에 대한 자동 추출에는 큰 문제가 없음을 확인하였으나, 건물 중에서 단독주택과 단독주택 외의 건물을 분류하는데는 다소 한계가 있음을 확인하였다. 다만, 본 연구는 다른 연구의 일부분으로 수행함에 따라 시간과 예산의 한계로 충분히 많은 데이터셋 구축과 보다 다양한 실험을 시도하는데 한계가 있었다. 향후 본 연구의 결과를 바탕으로 딥러닝 적용에 관한 다양한 연구가 진행된다면 기존의 토지피복분류, 변화탐지 및 모니터링이 가진 한계(시간, 비용)를 극복해 국토 전역에 대한 지속가능한 모니터링이 가능할 것으로 사료된다. 특히, 더 다양하고 많은 연구를 통해 국토부의 국토 모니터링이나 환경부의 토지피복도 갱신에 효과적으로 활용될 수 있는 방법론 개발을 모색할 필요가 있다.

#### 감사의글

본 연구는 2018년도 국토연구원의 기본연구 과제 “지속가능한 국토발전을 위한 토지이용변화 모니터링 방안 연구: 딥러닝 알고리즘 활용을 중심으로”에서 발제하여 정리한 논문이며, 연구에 도움을 주신 모든 분들에게 감사의 말씀을 전합니다.

#### 참고문헌

[1] 이현직, 유지호, 유영걸, 고해상도 위성영상을 이용한 정밀 주제 정보 추출, 한국지형공간정보학회지, 18, 73-81, 2010

- [2] 김배성, 박미성, 송성환, 민병걸, 인공 위성을 이용한 벼 재배면적 조사 시범연구, 나주: 한국농촌경제연구원, 2010
- [3] 조은래, 김경환, 유환희, 고해상도 위성영상을 이용한 토지이용변화 분석, 한국지형공간정보학회지, 17(1), 3-11, 2009
- [4] 김란희, 김현우, 이재희, 이승훈, 위성 자료를 이용한 북한지역 토지피복 및 식생 변화 추정, 국토연구, 90, 117-128, 2016
- [5] 차상인, 장동호, 원격탐사자료와 GIS 공간자료를 활용한 서산시 토지피복 변화 예측에 관한 연구, 한국사진지리학회지, 22(3), 183-198, 2012
- [6] 선우우연, 김다은, 강석구, 최민하, 서해연안 토지이용 및 토지피복 변화탐지를 위한 KOMPSAT-2 영상의 활용, 대한원격탐사학회지, 32(2), 141-153, 2016
- [7] 객근호, 2015. 토지계 오염원 관리를 위한 GIS기반의 토지피복지도 갱신 방법 개발 연구, 인하대학교 대학원 일반대학원
- [8] Inglada, J., Vincent, A., Tardy, B., Moring, D. and Fodes, I., "Operational High Resolution Land Cover Map Production at the Country Scale Using Satellite Image Time Series." Remote Sensing, 9(1), 2017
- [9] Qin, R., Huang, X., Gruen, A. and Schmitt, G., "Object-based 3D Building Change Detection on Multitemporal Stereo Images." IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 8(5), 2125-2137, 2017
- [10] 원석환, 머신러닝 기법을 적용한 통일 후 북한 도시 토지이용 변화 시뮬레이션, 경희대학교 박사학위논문, 2018
- [11] 송아람, 김용일, 딥러닝 기반의 초분광영상 분류를 사용한 환경공간정보시스템 활용, 대한원격탐사학회지, 33(6), 1061-1073, 2017
- [12] Cooner A. J., Yang, S., and Campbell, J. B., "Detection of Urban Damage Using Remote Sensing and Machine Learning Algorithms: Revisiting the 2010 Haiti Earthquake." Remote Sensing, 8(10), 2016
- [13] 통계청, 2014년 원격탐사 활용 경지면적조사 결과, 2월 27일, 보도자료, 2015
- [14] 지남석, 임병호, 대전광역시 주거여건 변화에 따른 주택지표 예측에 관한 연구, 대전: 대전발전연구원, 2016
- [15] Chen, L., Papandreou, G., Kokkinos, I., Murphy, K. and Yuille, A. L. "DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs." IEEE Transaction on Pattern Analysis and Machine Intelligence, 40(4), 834-848, 2018
- [16] Li, R., Liu, W., Yang, L., Sun, S., Hu, W., Zhang, F. and Li, W., "DeepU Net: A Deep Fully Convolutional Network for Pixel-level Sea-Land Segmentation." IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing(Early Access), 1-9, 2018
- [17] Fawcett, T., "An introduction to ROC analysis." Pattern recognition letters, 27(8), 861-874, 2006